



PRÁCTICA: SERIES TEMPORALES

Series Temporales y Minería de Flujos de Datos

Máster en Ciencia de Datos e Ingeniería de
Computadores

Ana Fuentes Rodríguez

Curso 2024/25

Índice

1. Objetivos	2
2. Metodología	2
3. Resultados	2
3.1. Análisis exploratorio de datos	2
3.2. Estudio previo de la estacionariedad	3
3.3. Modelado y eliminación de la tendencia y la estacionalidad	5
3.4. Experimentación para encontrar los parámetros (p, d, q) óptimos. Creación del modelo ARIMA	7
3.5. Predicción de valores futuros	10
4. Conclusiones	10

Resumen

En este trabajo se ha estudiado la predicción de series temporales. Para ello, se ha analizado la distribución que sigue una serie temporal (en concreto, la medida de temperatura en Australia desde el 2010 hasta el 2021), comprobando si esta serie es estacionaria o no. Además, se ha estudiado si dicha serie presenta tendencia o estacionalidad y, tras haber eliminado la estacionalidad (no presentaba tendencia), se ha modelado un algoritmo ARIMA con los mejores parámetros, entrenándose y evaluándose este modelo. Por último, se ha empleado este modelo (añadiéndole el modelo estacional) para predecir valores de temperatura futuros que no estaban incluidos en el conjunto de datos original.

1. Objetivos

El objetivo principal de la realización de esta práctica es familiarizarse con bibliotecas para trabajar con series temporales y resolver problemas de esta temática.

2. Metodología

Para poder llevar a cabo este estudio, se han seguido los siguientes pasos:

1. En primer lugar, se han cargado los datos presentes en el fichero “oikolab.csv” y se ha hecho un breve análisis exploratorio de los datos; distribución, valores faltantes y visualización de la serie.
2. En segundo lugar, se ha verificado si la serie presenta estacionariedad mediante un test de Dickey-Fuller. En caso de no ser estacionaria, se ha de realizar las transformaciones pertinentes (diferenciación para eliminar la posible tendencia o estacionalidad).
3. Seguidamente, se ha analizado la tendencia y la estacionalidad; descomponiendo la serie en estos dos factores (en caso de que la serie temporal tenga ambas partes).
4. A continuación, se ha realizado una selección de los parámetros del modelo ARIMA (p,d,q) utilizando ACF y PACF.
5. Posteriormente, se ha entrenado y validado el modelo, ajustando el modelo ARIMA y evaluar su desempeño. Además, se ha realizado predicciones para su evaluación, añadiendo al modelo ARIMA la tendencia y la estacionalidad previamente eliminadas.
6. Por último, se han realizado predicciones a futuro utilizando el modelo final.

3. Resultados

3.1. Análisis exploratorio de datos

En primer lugar, se han cargado los datos del archivo “oikolab.csv”. El dataframe generado presenta nueve columnas (incluida la variable temporal) y 100057 instancias. Este conjunto de datos no presenta valores nulos, por lo que no hay que hacer ningún preprocesamiento de los datos en lo referente a este aspecto. Es interesante además conocer la distribución que sigue la serie temporal. De este modo, se ha representado la temperatura en grados centígrados (°C) en función del tiempo (en horas), por lo que se ha reflejado en la Figura 1 esta distribución:




Figura 1: Representación gráfica donde se muestra la distribución de la temperatura (en °C) en función del tiempo (en horas).

En esta figura se puede observar una clara estacionalidad. Existe un claro patrón, cuyo período es anual; es decir, cada año se repite aproximadamente el mismo patrón. Esto tiene sentido, ya que en los meses de enero y febrero se observan las más altas temperaturas (se están estudiando temperaturas en Australia) y, progresivamente, disminuyen hasta llegar a un mínimo en los meses de julio y agosto aproximadamente y, posteriormente, vuelve a subir la temperatura y reiniciando el patrón.

Por otro lado, no se aprecia una tendencia aparente, ni ascendente ni descendente, pero se ha comprobado más adelante si realmente esta serie temporal presenta o no una tendencia significativa.

Para finalizar este análisis exploratorio de los datos, se ha pedido estudiar esta serie temporal de manera mensual, calculando la media de las temperaturas tomadas durante cada mes. Así pues, la serie temporal que se va a estudiar queda representada de la siguiente manera:




Figura 2: Serie temporal de las temperaturas medias mensuales desde enero de 2010 hasta junio de 2021.

Sigue sin observarse una tendencia clara, por lo que más adelante se analizará por separado para comprobar que, en efecto, esta serie no presenta tendencia.

3.2. Estudio previo de la estacionariedad

Una vez realizado un análisis exploratorio de los datos y un preprocesamiento de los mismos, se ha estudiado la estacionariedad de esta serie temporal. Para ello, se ha realizado un test de Dickey-Fuller, representando las funciones de auto correlación y auto correlación parcial con el fin de saber si es estacionaria o no. Así pues, las ACF y PACF obtenidas han sido las reflejadas en la Figura 3. También se ha reflejado la serie con su media móvil y su desviación típica en la Figura 4:




Figura 3: Gráficos obtenidos para la función de auto correlación (izquierda) y auto correlación parcial (derecha) referentes a la serie original sin procesamiento.




Figura 4: Serie original con su media móvil y su desviación típica para estudiar la estacionariedad.

El valor que se ha obtenido para p-value ha sido de 0.13. Este valor (superior a 0.05), junto con las gráficas previas, indica que esta serie no es estacionaria. Por lo tanto habría que preprocesar esta serie hasta conseguir que esta serie sea estacionaria. Por ejemplo, se ha realizado una diferenciación para comprobar si entonces la serie es estacionaria o no (reflejando la serie diferenciada en la Figura 5). De esta forma, se han obtenido las funciones ACF y PACF de la Figura 6 y el gráfico con la serie, su media móvil y su desviación típica de la Figura 7:




Figura 5: Gráfico donde se representa la distribución de la serie temporal diferenciada.




Figura 6: Gráficos obtenidos para la función de auto correlación (izquierda) y auto correlación parcial (derecha) referentes a la serie diferenciada.




Figura 7: Serie diferenciada con su media móvil y su desviación típica para estudiar la estacionariedad.

En este caso, el valor de p-value ha sido de $2.9 \cdot 10^{-16}$, por lo que ahora la serie ya sí es estacionaria. No obstante, si se observan tanto la función de auto correlación original (Figura 3) como la obtenida tras diferenciar (Figura 6), se puede comprobar cómo la estacionalidad afecta a la correlación entre los datos de la serie, por lo que, a la hora de estudiar este factor, se ha comprobado si afecta a la estacionariedad o no. Es decir, se ha trabajado con la serie original, si una vez eliminada la estacionalidad la serie es estacionaria, no sería necesario diferenciar.

3.3. Modelado y eliminación de la tendencia y la estacionalidad

Posteriormente, se ha realizado una descomposición de la serie original en los factores de tendencia, estacionalidad y residuos para comprobar si realmente los tienen. En la Figura 8, se han reflejado las distribuciones de la serie original, la tendencia, la estacionalidad y los residuos respectivamente:




Figura 8: Gráficos de la distribución de la serie original, tendencia, estacionalidad y residuos (mostrados de arriba a abajo).

En efecto, en la gráfica de la tendencia no se observa ninguna tendencia significativa. La variación se produce en un intervalo de 1.5 grados; al comienzo la temperatura media asciende, pero para los últimos años se observa de nuevo una bajada, por lo que no hay una tendencia clara, ni ascendente ni descendente.

Por otro lado, esta serie, como se comentaba previamente, sí presenta una evidente estacionalidad. De esta forma, y para poder trabajar e implementar un modelo ARIMA, se ha eliminado esta estacionalidad (de nuevo, de la serie original, no de la diferenciada) y se ha representado esta parte estacional en la Figura 9. Con esta modificación, se ha repetido el test de Dickey-Fuller para comprobar si la serie es estacionaria o, por el contrario, habría que diferenciar la serie (aunque visualmente no se observa tendencia). En la Figura 10 y en la Figura 11 se han mostrado las ACF y PACF y la serie con su media móvil y su desviación típica:




Figura 9: Gráfico donde se muestra la parte estacional de la serie temporal.




Figura 10: Gráficos obtenidos para la función de auto correlación (izquierda) y auto correlación parcial (derecha) referentes a la serie temporal sin la componente estacional.




Figura 11: Serie temporal sin estacionalidad con su media móvil y su desviación típica para estudiar la estacionariedad.

Tras realizar este test, el resultado del p-value ha sido de $3.4 \cdot 10^{-14}$. Observando además las funciones de auto correlación (la correlación cae rápidamente), se puede concluir que la serie sí es estacionaria. De este modo, no es necesario diferenciar, sino que con haber eliminado la estacionalidad ya se cumple la condición de estacionariedad.

3.4. Experimentación para encontrar los parámetros (p, d, q) óptimos. Creación del modelo ARIMA

A continuación, se ha buscado el mejor modelo ARIMA para este conjunto de datos en concreto. El primer paso es encontrar los valores para los parámetros p (autorregresión), d (diferenciación) y q (media móvil).

Como la serie ya es estacionaria, no hace falta diferenciar, por lo que la parte de la diferenciación tomará un valor nulo (es decir, $d = 0$).

Ahora bien, para conocer los mejores parámetros para la parte de autorregresión y de media móvil pueden observarse los gráficos de las funciones de auto correlación y auto correlación parcial. Por un lado, con el gráfico ACF se puede obtener el valor de p , contando los valores que se encuentran por encima del intervalo de confianza (en este caso, $p = 3$). Por otro lado, observando el gráfico PACF se obtiene q del mismo modo (en este caso, $q = 2$).

Entonces, el modelo teóricamente óptimo sería un modelo ARIMA con parámetros $(3, 0, 2)$. Experimentalmente, se ha implementado un GridSearch de p y q entre los valores $p, q = 0, 1, 2, 3$ para obtener el mejor modelo, obteniendo, en efecto, un modelo con los parámetros $p = 3$, $d = 0$ y $q = 2$.

Una vez encontrado este modelo ARIMA y haberlo entrenado, el siguiente paso es estudiar sus residuos con el fin de comprobar que estos cumplen las dos condiciones que deben respetar (si no las cumplen, ha de existir un mejor modelo para este problema). Así pues, se han obtenido los gráficos de la Figura 12:




Figura 12: Análisis gráfico de los residuos obtenidos con el modelo ARIMA(3,0,2).

Como se ha comentado anteriormente, los residuos deben cumplir dos requisitos para poder considerar que el modelo elegido es un buen modelo:

1. Residuos no correlacionados: no debe existir ninguna correlación entre los residuos. En caso de haberla, habría algún patrón que podría ser detectado por un modelo mejor.
2. Media cero: la media de los residuos debe ser aproximadamente nula, es decir, no puede existir un sesgo en los residuos. Del mismo modo que ocurría con la correlación, si los residuos estuvieran sesgados (hacia derecha o izquierda), existiría algún patrón que podría ser detectado por un mejor modelo.

Analizando entonces los gráficos de la Figura 12, se puede concluir, por un lado, que los residuos presentan una fluctuación alrededor del cero (como indica la gráfica superior izquierda), lo que indica una media aproximadamente nula. Además, el histograma del gráfico superior derecho muestra una distribución aproximadamente simétrica y, efectivamente, centrada en cero.

Por otro lado, la función de correlación (el correlograma situado abajo a la derecha) indica que los residuos no tienen ninguna relación de correlación entre ellos, salvo el primer rezago que se encuentra fuera del intervalo de confianza. Esto puede indicar que el modelo elegido podría recibir un mayor ajuste para refinar esta pequeña correlación, pero el modelo trabaja aparentemente bien.

Tras entrenar y validar el modelo ARIMA(3,0,2), se ha generado un gráfico para comparar los datos de entrenamiento y test con los generados por el modelo. Esta gráfica se ha representado en la Figura 13:




Figura 13: Gráfico donde se comparan los datos originales de entrenamiento y prueba con los datos que genera el modelo para el entrenamiento y el test.

Antes de terminar, se ha realizado una predicción de los datos que se han reservado para test. Para ello, se ha realizado la predicción para estos datos (últimos 12 meses del dataset, de junio de 2020 a mayo de 2021) y se le ha añadido el modelo estacional. Finalmente, se ha obtenido el gráfico comparativo de la Figura 14 entre los datos reales y la predicción con el fin de evaluar el modelo




Figura 14: Gráfico que representa la serie original además de la predicción que realiza el modelo para el conjunto de test (últimos 12 meses que aparecen en el dataset).

Observando el gráfico y teniendo en cuenta que el error de validación MSE ha sido de 0.83, se puede concluir que el modelo trabaja de manera eficiente y tiene un buen rendimiento, arrojando buenos resultados. En el gráfico se comprueba que se comete un mayor error en los valores más extremos de la temperatura, mientras que para las temperaturas medias (meses de abril, mayo o septiembre, octubre, aproximadamente)

se solapa la predicción sobre los datos reales, generando predicciones prácticamente exactas.

3.5. Predicción de valores futuros

Por último, se ha utilizado este modelo ya entrenado para realizar predicciones a futuro. En concreto, se han predicho los valores de temperatura de junio a diciembre de 2021 (ambos incluidos). Para ello, se ha utilizado el modelo para predecir los 7 meses siguientes a los presentes en el dataset y se le ha añadido el modelo estacional, obteniéndose los resultados de la Figura 15, donde se ha mostrado la serie original junto con la predicción realizada:




Figura 15: Gráfico donde se representa la distribución de la serie temporal original junto con la predicción que ha obtenido el modelo para los meses de junio a diciembre de 2021.

Como se puede comprobar, se han obtenido resultados razonables, ya que en junio la temperatura es mínima, mientras que en diciembre la temperatura es máxima.

4. Conclusiones

Tras la realización de esta práctica, se ha podido concluir que la serie temporal estudiada carece de tendencia, puesto que el rango de temperaturas a lo largo de los años ha permanecido aproximadamente constante, es decir, no se ha observado un crecimiento o decrecimiento relevante de la temperatura (en los primeros años aumenta, se mantiene constante y disminuye en los últimos años).

Por otro lado, presenta una evidente estacionalidad a lo largo de cada año; en los primeros meses del año la temperatura alcanza un máximo, la cual va decayendo conforme pasan los meses, hasta llegar a un mínimo alrededor de junio, a partir del cual vuelve a aumentar la temperatura hasta llegar a diciembre. Este ciclo se ha repetido de manera periódica durante todos los años estudiados (entre el 2010 y el 2021). Es importante también destacar cómo ha afectado la presencia de la estacionalidad a la estacionariedad de la serie, ya que, cuando se ha eliminado la estacionalidad la serie ya cumplía la condición de estacionariedad, sin necesidad de aplicar más transformaciones a dicha serie.

Tras generar un modelo ARIMA (con los parámetros $p = 3$, $d = 0$ y $q = 2$), se ha comprobado las características de los residuos con el fin de verificar que este es el mejor modelo. Aunque existe una pequeña correlación en los residuos, su distribución no se encuentra sesgada, por lo que es el mejor modelo dentro de los estudiados.

Por último, después de haber entrenado y evaluado este modelo, se ha realizado una predicción a futuro, prediciendo los valores de temperatura media al mes desde junio hasta diciembre de 2021, obteniendo buenos resultados, puesto que se asemejan a los obtenidos años anteriores (mínima temperatura en junio y máxima en diciembre, ascendiendo de manera progresiva). Por lo tanto, se puede concluir que el modelo seleccionado es un buen modelo, que trabaja de manera óptima y eficiente.